
# ログ・係数集約と可視化・分析

### **Agenda**

- Fluentd
- Embulk
- ElasticStack6.0


### Fluentdとは

- Fluentdはシンプルにログ収集ができる
- 一 データ連携のハブ
- 拡張性の高いストリーミングログコレクタ



### Fluentdとは

- 「CNCF(Cloud Native Computing Foundation)」の管理するプロジェクト
- Kubernetes や Prometheus といったクラウドネイティブな OSS 技術の推進を行う団体
- Kubernetes環境におけるログ収集ツールの 標準 となった



# Fluentd & td-agent

- Fluentd
  - 最新バージョンはv1.1.3 2018/04/03
  - Fluentdのコアソフトウェア
  - 一プラグインは個別に利用者側でインストール
  - 最新を試したい場合はFluentd本体を使う
- td-agent
  - Fluentdに各種プラグインやRuby環境を組み込んだパッケージ
  - 主要環境でgemコマンドによるインストールが可能
    - Linuxへのインストールも容易
  - サポートOSに制約があるが依存関係の問題がほぼなし
    - トレジャーデータ側で検証済なので本番、安定稼働がいいのはtd-agent

### ユースケース

- 1. ログの収集
  - ログをローカルディスクから、RDB等に渡すことができる ログの欠損は高可用性を維持することで防げる
- 簡単なリアルタイム集計 プラグインを利用することで、リアルタイムでステータスコードを含んだ 口グを遅れる 可視化ツールでグラフ化などもできる。
- 3. センサーログ収集 センサー(ラズパイ)からゲートウェイに集めて、ログサーバに集計する。

### 利用しない方がいいケース

- 一 ログの欠損も重複も許さず、確実に書き込む必要があるというケース
  - 課金データなど

# 非同期メッセージングサービスQoS

ネットワーク上で提供する機能を安定的に稼働させるために行う、サービス品質管理技術

At Most Once(デフォルト)	At Least Once(オプション)	Exactly Once(サポートされ
		ていない)
到達保証なし	到達保証あり	到達保証あり
投げる側が一度で投げること	投げる側が一度で投げること	投げる側、受け取る側ともに 一度で配信されること
欠損の可能性あり	欠損しない	欠損しない
重複しない	重複の可能性	重複しない

### v0.12バージョン

#### old stable

- プラグイン: Input, Parser, Filter, Output,

### Formatter, Buffer

- 以下のような問題がある
- 秒単位のみ
- windows未対応
- multi core未対応
- プラグインが貧弱

### v0.14以降のバージョン

v0.14 v1の開発バージョン

- プラグイン: Input, Parser, Filter, Output, Formatter, Storage,

#### Buffer

- 改善点
- New Plugin APIs
- ミリ秒対応
- windows対応
- multi core対応
- New Plugin Helpers & Plugin Storage

### v0.14以降のバージョン

v1.0はv0.14と機能が同じでstableバージョン。

名前を変更しただけ。

最新バージョンはv1.1.3 - 2018/04/03

td-agent3は2017年の12月からstable版がでており、Fluentd v1ベースになっている。

### v0.122v1

- v0.12 APIを使用するプラグインは、Fluentd v0.14とv1の間でサポートされる(v2で廃止される予定)
- Fluentd v1は、起動時に自動的にv0.12スタイルをv1.0スタイルに変換するので、v0.12の設定をv1で再利用可能
- Fluentd v1.0の新機能は、新しいAPIを使用するプラグインでのみ使用可能
  - flexible chunk keys
  - placeholders
- Fluentd v0.12.xでは新しいAPIを使用するプラグインは動作しない

### v0.12とv1の設定の違い

v1はoutputのバッファパラメータに<buffer>sectionを使っている

```
# v1
<match pattern>
 @type foo
 database db1
 apikey foobarbaz
 # buffer parameters
  <buffer>
   @type file
    path /path/to/buffer
   flush_interval 10s
 </buffer>
</match>
# v0.12
<match pattern>
 @type foo
 database db1
 apikey foobarbaz
 # buffer parameters
  buffer_type file
  buffer_path /path/to/buffer
  flush_interval 10s
</match>
```

### fluent-plugin-bigquery

- 最新v2.0.0.beta
- schemeが間違っていると無限にretryしていた。
- v0.2.13以降ではデータがinvalidなのにretryかけても意味無いので、retryableな例外の時だけ例外上げ直して、その他の例外の時にはretry\_stateを弄ってリトライを強制停止している。

### fluent-plugin-bigquery(v.1.2.0) Ooutbigqueryinsert.rb

```
def insert(project, dataset, table_id, rows, schema, template_suffix)
  writer.insert_rows(project, dataset, table_id, rows, template_suffix: template_suffix)
rescue Fluent::BigQuery::Error => e
 if @auto_create_table && e.status_code == 404 && /Not Found: Table/i =~ e.message
    # Table Not Found: Auto Create Table
   writer.create_table(project, dataset, table_id, schema)
    raise "table created, send rows next time."
  end
  raise if e.retryable?
 if @secondary
   # TODO: find better way
   @retry = retry_state_create(
     :output_retries, @buffer_config.retry_type, @buffer_config.retry_wait, @buffer_config.retry_timeout,
     forever: false, max_steps: @buffer_config.retry_max_times, backoff_base: @buffer_config.retry_exponential_backoff_base,
     max_interval: @buffer_config.retry_max_interval,
     secondary: true, secondary_threshold: Float::EPSILON,
     randomize: @buffer_config.retry_randomize
  else
   @retry = retry_state_create(
      :output_retries, @buffer_config.retry_type, @buffer_config.retry_wait, @buffer_config.retry_timeout,
     forever: false, max_steps: 0, backoff_base: @buffer_config.retry_exponential_backoff_base,
     max_interval: @buffer_config.retry_max_interval,
     randomize: @buffer_config.retry_randomize
  end
  raise
end
```

# Fluentd v1.2にはretryの挙動が変わりそう。

Fluentdのoutput oluginは、chunk flush中に復帰不可能なエラーを発生するが、

これらのチャンクを処理するために retry limit と secondary を使っている。


— 再開時に破損したfilechunkをskipして削除

https://github.com/fluent/fluentd/pull/1874

— chunkのflush中にoutput pluginが回復不可能なエラーを

InputからOutputへ情報が渡される仕組みにおいて Output側ではBufferとQueueという仕組みがある。 これがログの欠損をしない仕組みにしている。

- 最初に情報が入ってくるBufferという機能の最大サイズ: buffer\_chunk\_limit
- 次にQueueという部分にchunkが押し出されるがQueueで何個までchunkを蓄えられるか: buffer\_queue\_limit
- enqueue: buffer\_chunk\_limit を超えた場合押し出される場合と flush\_interval を経過した場合渡されるケース
- それぞれ設定すれば柔軟に口グを送ることができる



### Outputのパラメータ

パラメータ	内容
buffer_type	バッファの種類(file,memory)
buffer_path	ファイルバッファの格納先
bufferchunklimit	chunck最大サイズ
bufferqueuelimit	Queue内chunck最大数
flush_interval	バッファフラッシュ間隔

```
<match access.**>
  @type forward
  buffer_type file
  buffer_path /var/log/td-agent.buffer
  buffer_chunk_limit 8m #8MBを保持する
  buffer_queue_limit 64 #64個まで蓄える
  flush_interval 60s # BufferからQueueに渡される場合60秒たったら中身のchunckをQueueに渡す
  <server>
    name test_server
    host 192.168.33.11
    port 24224
  </server>
</match>
```

蓄えるDiskの容量やメモリのサイズは buffer\_chunk\_limit x buffer\_queue\_limit をかけ合わせたものが領域としてBufferのサイズとして必要になる matchの数だけこのかけ合わせた値が必要になるので注意が必要。

#### バッファ設計(v1)


内部的には、バッファプラグインには、チャンクがイベントでいっぱいになる「ステージ」と、

チャンクが転送前に待機する「キュー」という 2つの分離された場所 があります。

新しく作成されたすべてのチャンクは、ステージから開始し、時間内にキューに入れられます(その後、宛先に転送されます)。

- staged:buffering 状態
- queued:flush待ちのqueueに入っている状態

#### バッファ設計(v1)



#### **Embulk**

最新バージョン0.9.7(2018-04-16) バルク版のFluentd バッチ的な転送

- ― オープンソースの並列分散処理バルクローダー
- 一プラグインアーキテクチャ
- 一容易なデータインテグレーションの実現

### Embulkのユースケース

- ― 過去分の情報を解析したい
- 一 バッチ的にデータを転送したい
- ― 異なるストレージにデータを同期したい
- 一 大きな1ファイルだけを転送したい

### FluentdとEmbulkの使い分け

- Fluentd
  - WEB/APPサーバのログ収集
  - 一 監視、モニタリング
  - 流量の大きいログ収集
  - リアルタイム性の高い分析用途
  - バッチで溜め込むと送れないもの
- Embulk
  - マスタデータの同期
  - 一日ごとのデータ移動(バッチ的)
  - S3などからの並列データダウンロード
  - DWHへのデータロード

### バージョン

- 0.9.0 (2018-01-30)
- Java 8
- Lambda
- Stream
- Time
- Async File IO
- FileSystem
- Oracle Java SEサポート・ロードマップ
- LTS バージョンが、3年ごとのリリースを目標
- 機能リリースは、6ヶ月ごとを目標

### バージョン

- 0.9.3(2018-02-13)
- JRubyベースのプラグインが使用されていない場合、JRuby の初期化を停止
- プラグインのロードと起動が速くなっている
- 0.9.7(2018-04-16)
- 最新バージョン

#### embulk-announce

Embulkの新バージョンのリリース通知、互換性に関する通知など開発者からのアナウンス専用ML

https://t.co/w8TFtr30u0

#### ElasticStack6.0

6.2.0 リリース(2018-02-06)

検索と分析のスタックとして機能するコンポーネントのエコシ

ステム

- Kibana
- Logstash
- Beats
- X-Pack
- Elasticsearch

### 各コンポーネントの役割

- Elasticsearchすべてのデータを格納し、検索機能と分析機能をスケーラブルに提供
- Logstashログ、メトリックなどのイベントデータを任意の形式で集中管理
- Beats
   Filebeatは、サーバーからLogstashやElasticsearchにログファイルを配信するために構築されたBeat
   Metricbeatは、サーバー上で実行されているOSやサービスから定期的にメトリックを収集するサーバー監視エージェント
- kibana Elastic Searchの視覚化ツール
- X-Pack Elastic Stackにセキュリティ、監視、アラート、レポート、およびグラフ機能を追加 コードが公開。

### お役立ち情報まとめ

- Fluentd
   Fluentd v1 and future at techtalk
   プラグイン開発者から見るfluentd v1.0の活用法
   fluentd の基礎知識
- EmbulkEmbulk v0.9Embulk
- BigdamBigdam
- ElasticStackdiscuss.elastic.co